



Comprendre le monde,
construire l'avenir



UNIVERSITÉ PARIS-SUD

MASTER AIC

TC5 - TRAITEMENT DES IMAGES ET DU SIGNAL

RAPPORT DE PROJET

Reconnaissance faciale en utilisant les eigenfaces

Auteurs :

Ghiles SIDI SAID

Mohamed Ali DARGHOUTH

Walid BELRHALMIA

31 décembre 2017

Table des matières

Introduction	3
1. Méthode proposée par l'article et résultats obtenus	3
1..1 Présentation des eigenfaces	3
1..2 Classification bayésienne	3
1..3 Étapes de la méthode	4
1..4 Résultats obtenus par la méthode	5
1..5 Critique de la méthode de test	5
2. Notre implémentation	5
2..1 Base de données	5
2..2 Méthodologie de test	6
2..3 Résultats obtenus	6
3. Étude de la robustesse du système	6
3..1 Robustesse au nombre de personnes	6
3..2 Robustesse au bruit	7
3..3 Robustesse à l'inversion de contraste	11
3..4 Robustesse à la rotation	12
Conclusion	12
Références	13

Table des figures

4		
2	Étape d'apprentissage.	4
3	Système déployé.	5
4	Échantillon des images de la base de données AT&T.	5
5	Taux de reconnaissance en fonction de la variance du bruit blanc gaussien (apprentissage sur des données non bruitées).	7
6	Exemple de bruit blanc gaussien de différentes variances.	8

Introduction

La reconnaissance faciale est une méthode de reconnaissance biométrique qui consiste en l'identification d'un individu à partir d'une image de son visage. Étant donné qu'un visage est unique à une personne (sauf dans des cas très rares de jumeaux identiques où même un être humain ne peut pas faire la différence), la reconnaissance faciale est très adaptée pour l'identification d'un individu.

La reconnaissance faciale a fait l'objet de plusieurs travaux de recherche ces dernières décennies, on la retrouve aujourd'hui dans plusieurs secteurs de la vie quotidienne comme les systèmes de contrôle d'accès, les systèmes de registre de présence, mais également dans les réseaux sociaux.

Dans ce projet, nous avons travaillé sur l'article () qui propose une méthode basée sur les vecteurs propres des images de visages (appelés "eigenfaces", ce qui pourrait être traduit en "visages propres" en français. Par la suite nous allons utiliser le terme "eigenfaces"). C'est une méthode peu coûteuse en puissance de calcul, ce qui contraste avec les méthodes standards actuelles qui utilisent des modèles obtenus par apprentissage profond (Deep Learning) qui nécessitent un temps et une puissance de calcul considérables pour être appris, mais dont le taux de réussite aujourd'hui atteint les 99%.

Dans ce rapport, nous allons dans un premier temps expliquer la méthode proposée par () et montrer les résultats obtenus. Ensuite, nous allons présenter notre propre implémentation de la méthode ainsi que les résultats que nous avons obtenu. Enfin, nous allons étudier la robustesse de la méthode au nombre de personnes, aux bruits, à l'inversion de contraste, à la rotation, et à la translation.

1. Méthode proposée par l'article et résultats obtenus

Dans ce chapitre, nous allons d'abord présenter ce qu'on appelle les "eigenfaces". Nous allons ensuite faire une brève présentation de la méthode de classification "bayésien naïf". Nous exposerons alors les différentes étapes de la méthode proposée par (PSG16, SG16) ainsi que les résultats obtenus. Nous finirons par une critique de la démarche de test de (PSG16, SG16).

1.1 Présentation des eigenfaces

Soit un ensemble d'images de visages. On transforme chaque image, qui est un signal discret à deux dimensions, en un vecteur à une dimension (on travaille avec des images en niveaux de gris). On calcule alors la matrice de variance-covariance de ces vecteurs. On appelle eigenfaces les vecteurs propres de cette matrice.

Plus formellement : soit l'ensemble d'images $\{I_1, I_2, \dots, I_M\}$. Les étapes pour trouver les eigenfaces sont :

1. Transformer chaque image I_i , qui est en deux dimensions, en un vecteur Γ_i à une dimension.
2. Calculer le vecteur moyen $Y : Y = \frac{1}{M} \sum_{i=1}^M \Gamma_i$.
3. Soustraire le vecteur moyen Y de chaque vecteur $\Gamma_i : \phi_i = \Gamma_i - Y$.
4. Calculer C , la matrice variance-covariance des vecteurs $(\phi_i)_{i=1}^M : C = A^T A$, où la ligne i de A est ϕ_i .
5. Calculer la matrice u , dont chaque colonne correspond à un vecteur propre de C . Les colonnes de u sont les eigenfaces.

Si N est le nombre de pixels d'une image, alors C est une matrice $N \times N$. Pour N assez grand (ce qui est très souvent le cas quand on travaille sur des images), le calcul des vecteurs propres de C devient vite très coûteux. Au lieu de faire cela, on calcule les vecteurs propres de AA^T (ils sont au nombre de M , le nombre d'images, sachant que dans la plupart des cas $M \ll N$). Alors, pour chaque vecteur propre v de AA^T , $u = Av$ est un vecteur propre de C . Ça nous permet d'obtenir M vecteurs propres (M étant le nombre d'images) qui sont considérés les eigenfaces et qui forment une base de l'espace vectoriel des images.

1.2 Classification bayésienne

Soit un problème de classification où les individus sont représentés par la variable aléatoire X et les classes par la variable aléatoire Y . La classification bayésienne repose sur le fait de classer un individu x dans la classe y qui maximise la probabilité : $P(Y = y|X = x)$.

Le théorème de Bayes nous dit que :

$$P(Y = y|X = x) = \frac{P(X = x|Y = y) \times P(Y = y)}{P(X = x)}$$

Donc pour maximiser $P(Y = y|X = x)$, il suffit de maximiser $P(X = x|Y = y) \times P(Y = y)$ (puisque $P(X = x)$ ne dépend pas de y et nous cherchons à maximiser selon y). On peut facilement estimer $P(Y = y)$ (par un simple comptage dans l'échantillon par exemple). Le problème réside dans le calcul de $P(X = x|Y = y)$ sachant que X est dans \mathbb{R}^d , c.a.d. que $X = (X_1, X_2, \dots, X_d)$ où $X_i \in \mathbb{R}$.

L'hypothèse "naïve" sur laquelle se base la classification bayésienne est de supposer les variables aléatoires X_i indépendantes (d'où le nom "bayésien naïf" ou "naïve bayes" en anglais). Quand on fait cette hypothèse, il devient plus facile de calculer $P(X = x|Y = y)$. En effet :

$$P(X = x|Y = y) = P(X_1 = x_1, X_2 = x_2, \dots, X_d = x_d|Y = y) = \prod_{i=1}^d P(X_i = x_i|Y = y)$$

Il suffit alors d'estimer $P(X_i|Y = y)$ pour chaque $i \in \{1, 2, \dots, d\}$, ce qui est bien plus facile à faire, et requière beaucoup moins de paramètres à estimer que dans le cas où on devrait estimer $P(X|Y = y)$. Les hypothèses les plus couramment utilisées sur $P(X_i|Y = y)$ sont que la distribution est gaussienne ou binomiale.

1.3 Étapes de la méthode

Comme le montre la figure 1, la méthode se décompose en deux étapes : apprentissage du modèle et déploiement du modèle.




FIGURE 1 – Étapes de la méthode de (PSG16, SG16).

Toutes les images sont préalablement converties en niveaux de gris.

Apprentissage du modèle

On utilise un classifieur bayésien dans lequel on suppose que $P(X_i|Y = y)$ suit une distribution gaussienne ($X_i|Y = y \sim N(\mu_{iy}, \sigma_{iy})$). L'étape d'apprentissage permet d'estimer les paramètres du modèle (μ_{iy} et σ_{iy} pour chaque i et chaque y). La figure 2 montre les différentes étapes de l'apprentissage, celles-ci sont :

1. À partir des images d'entraînement, calculer les eigenfaces comme indiqué dans la sous-section 1.1. Ces eigenfaces forment une base de l'espace vectoriel des visages (facespace).
2. Pour chaque image I de la base d'entraînement :
 - (a) Transformer I , qui est une image en deux dimensions, en un vecteur Γ à une dimension.
 - (b) Trouver les coordonnées de Γ dans la base eigenfaces (en faisant un produit scalaire avec chaque eigenface). On obtient les coordonnées (x_1, x_2, \dots, x_M) où M est le nombre de pixels d'eigenface, qui est également le nombre d'images dans la base de données d'entraînement.
 - (c) Faire passer (x_1, x_2, \dots, x_d) à l'entrée du classifieur bayésien pour qu'il apprenne les paramètres.

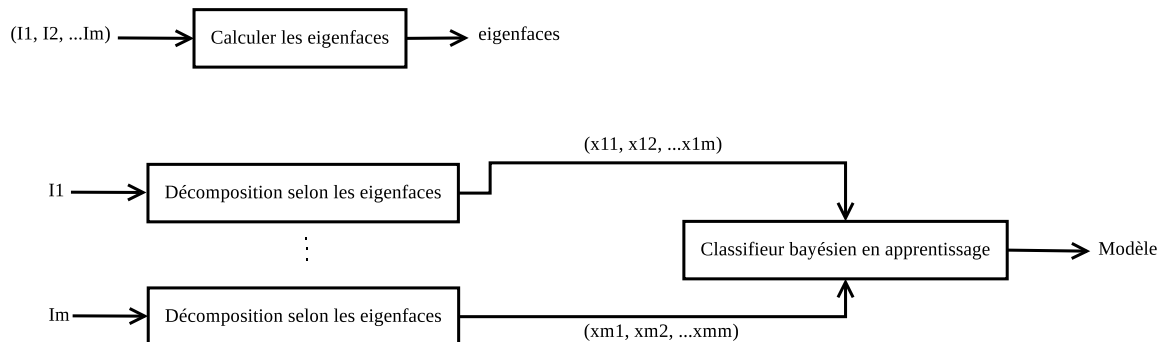


FIGURE 2 – Étape d'apprentissage.

À la fin de cette étape, on aura l'ensemble des eigenfaces et un classifieur bayésien entraîné.

Déploiement du modèle

Une fois le modèle appris, on peut reconnaître de nouvelles images. Quand on a une nouvelle image d'un visage, on calcule ses coordonnées dans la base des eigenfaces et on fait passer ces coordonnées à l'entrée du classifieur bayésien qui nous donne en sortie la personne à laquelle appartient le visage. Le visage doit appartenir à une personne qui existe dans la base de données d'entraînement. La figure 3 résume cette étape.




FIGURE 3 – Système déployé.

1.4 Résultats obtenus par la méthode

Les auteurs de (PSG16, SG16) ont travaillé sur une base de données de 200 images de 20 personnes, avec donc 10 images par personne. Le taux d'images correctement classées est de 70%. En normalisant (centrer, réduire) les valeurs des vecteurs propres (eigenfaces), les auteurs affirment avoir obtenu un taux de réussite de 89.5%.

1.5 Critique de la méthode de test

Pour les calculs des eigenfaces, les auteurs de (PSG16, SG16) ont utilisé toutes les images de la base de données (pas de séparation en données d'entraînement et de test). Ensuite, ils ont fait de la validation croisée pour entraîner le classifieur bayésien et estimer le taux de succès de la méthode. Mais étant donné que même les données de test ont été utilisées pour la génération des eigenfaces, les résultats obtenus sont biaisés, les données de tests ne doivent pas du tout entrer dans le processus de génération du modèle.

2. Notre implémentation

2.1 Base de données

La base de données d'images que nous avons utilisé est la base AT&T (lien : <http://www.cl.cam.ac.uk/research/dtg/attarchive/facedatabase.html>). C'est une base de 400 images de visages de 40 personnes, avec 10 images par personne. Les visages sont bien centrés sur l'image et l'arrière-plan est très peu apparent ; ça correspond au genre d'images utilisé pour les photos d'identité. La figure 4 montre un échantillon des images de la base.



FIGURE 4 – Échantillon des images de la base de données AT&T.

Les images sont en niveaux de gris et ont une taille de 92×112 .

2..2 Méthodologie de test

Étant donné que nous avons un nombre limité d'images, nous ne pouvons pas nous permettre de partitionner l'ensemble des 400 images en données d'entraînement et de test ; la variance des résultats obtenus les rendrait inexploitable (à vrai dire on a essayé ça, le taux de classification correcte varie entre 50% et 80% pour deux choix aléatoires des données d'entraînement et de test, ce qui est une marge trop large).

Pour tester les performances du système, nous allons utiliser la validation croisée. La validation croisée est une méthode d'estimation des performances d'un algorithme d'apprentissage automatique. On divise l'ensemble des images en k échantillons, puis on sélectionne un des k échantillons comme ensemble de test et les $k - 1$ autres échantillons comme ensemble d'apprentissage. On apprend le modèle sur l'ensemble d'apprentissage et on mesure le taux de classification correcte sur l'ensemble de test. On répète l'opération en sélectionnant un autre échantillon de test parmi les $k - 1$ échantillons qui n'ont pas encore été utilisés pour tester le modèle. L'opération se répète ainsi k fois pour de sorte que chaque sous-échantillon ait été utilisé exactement une fois comme ensemble de test. La moyenne des k taux de classification correcte servira d'estimation finale du taux de classification correcte du système.

Dans notre cas, nous avons pris $k = 10$. Pour chaque personne, 9 images d'entraînement et une de test pour chaque itération. À noter que contrairement à ce qui a été fait dans (PSG16, SG16), les eigenfaces ont été calculées en utilisant uniquement les données d'entraînement, ce qui permet d'avoir une estimation plus correcte des performances du système.

2..3 Résultats obtenus

Nous avons obtenu un taux de reconnaissance correcte de 68%, ce qui est proche du taux obtenu par (PSG16, SG16) sans normalisation des eigenfaces (à savoir 70%). Notre taux de 68% a été obtenu en normalisant les eigenfaces, cette normalisation n'influence que très peu le taux de reconnaissance.

Il est à mentionner que nous avons travaillé avec 40 classes, et (PSG16, SG16) ont travaillé avec 20 classes. Quand nous réduisons le nombre de classes à 20 (et donc le nombre d'images à 200), nous obtenons un taux de reconnaissance correcte de 82%, ce qui est assez proche du taux de 89.5% obtenu par (PSG16, SG16).


3. Étude de la robustesse du système

Nous allons étudier la robustesse du système par rapport au nombre de personne, le bruit, l'inversion du contraste, la rotation et la translation.

3..1 Robustesse au nombre de personnes

Nous avons déjà dit lorsque nous avons présenté nos résultats que quand il y a 40 personnes, le taux de reconnaissances correctes est de 68%, alors que quand il y a 20 personnes, celui-ci est de 82%. Ce large écart nous pousse à étudier l'influence que peut avoir le nombre de personnes sur les performances du système.

La figure ?? montre l'évolution du taux de reconnaissances correctes en fonction du nombre de personnes. On voit que...



Malheureusement, comme il y a 40 personnes dans la base de données AT&T, on ne peut pas tester pour des valeurs supérieures à 40.

3.2 Robustesse au bruit

Bruit blanc gaussien

On entraîne le système sur des données non bruitées puis on le teste sur des images bruitées. La figure 5 montre les variations du taux de reconnaissances correctes en fonction de la variance σ^2 du bruit blanc gaussien.




FIGURE 5 – Taux de reconnaissance en fonction de la variance du bruit blanc gaussien (apprentissage sur des images non bruitées).

Pour mieux visualiser la chose, la figure 6 montre une image non bruitée et la même image avec des bruits gaussiens de différentes variances.




FIGURE 6 – Exemple de bruits blancs gaussiens de différentes variances.

Nous voyons que les performances commencent à décroître dès que le bruit devient apparent. Pour une variance supérieure à 0.1, on n’attend pas du système qu’il ait de bonnes performances car même un être humain aurait des difficultés à reconnaître la personne.

Maintenant, au lieu d’entraîner sur des données non bruitées et de tester sur des données bruitées, nous allons introduire un pourcentage (30%) d’images bruitées dans les images d’entraînement et de test. Le graphe de la figure ?? montre les taux de reconnaissance obtenus pour différentes variances.




FIGURE 7 – Taux de reconnaissance en fonction de la variance du bruit blanc gaussien (apprentissage sur des images bruitées).

Les performances cette fois-ci sont inférieures à celles que nous avons obtenu lorsque nous avons utilisé uniquement des données non bruitées pour l’entraînement. Nous suspectons que l’introduction de bruits dans les données d’entraînement a conduit à une mauvaise reconnaissance des images non bruitées (en plus des images bruitées).

On conclue que le système est peu robuste aux bruits gaussiens. Ces résultats sont toutefois à prendre avec précaution étant donné le nombre limité d’images disponibles.

Bruit de Poisson

La figure 8 montre une image avant et après application d’un bruit de Poisson. Après avoir entraîné le système sur des images non bruitées, quand on teste sur des images bruitées (bruit de Poisson), le taux de reconnaissances correctes est de 68%, le même que sur des données non bruitées. On en conclue que le système est robuste aux bruits de Poisson.




FIGURE 8 – Exemple d'un bruit de Poisson.

Bruit Speckle

On entraîne le système sur des données non bruitées puis on le teste sur des images bruitées. La figure 9 montre les variations du taux de reconnaissances correctes en fonction de la variance σ^2 du bruit speckle.




FIGURE 9 – Taux de reconnaissance en fonction de la variance du bruit speckle.

Pour mieux visualiser la chose, la figure 10 montre une image non bruitée et la même image avec des bruits speckle de différentes variances.




FIGURE 10 – Exemple de bruits speckle de différentes variances.

Nous voyons qu'il y a une détérioration des performances à mesure que le bruit speckle devient apparent, mais le système conserve quand-même un taux de reconnaissance assez satisfaisant (comparé à ses performances dans le cas sans bruits). On en conclue que le système est assez robuste au bruit speckle (Il n'est pas totalement robuste, ses performances diminuent là où celles d'un être humain resteraient les mêmes).

Bruit poivre et sel

On entraîne le système sur des données non bruitées puis on le teste sur des images bruitées. La figure 11 montre les variations du taux de reconnaissances correctes en fonction du pourcentage des pixels de l'image affectés par le bruit poivre et sel.




FIGURE 11 – Taux de reconnaissance en fonction du pourcentage des pixels bruités (bruit poivre et sel).

Pour mieux visualiser la chose, la figure 12 montre une image non bruitée et la même image avec des bruits poivre et sel affectant différents pourcentages de pixels.




FIGURE 12 – Exemple de bruits poivre et sel affectant différents pourcentages de pixels (apprentissage sur des images non bruitées).

Nous voyons que les performances commencent à décroître dès que le bruit devient apparent, donc à la base, le système n'est pas robuste aux bruits poivre et sel.

Maintenant, au lieu d'entraîner sur des images non bruitées et de tester sur des images bruitées, nous allons introduire un pourcentage (30%) d'images bruitées dans les images d'entraînement et de test. Le graphe de la figure 13 montre les taux de reconnaissance obtenus pour différents pourcentages de pixels affectés.




FIGURE 13 – Taux de reconnaissance en fonction du pourcentage des pixels affectés par le bruit poivre et sel (apprentissage sur des images bruitées).

Les performances cette fois-ci sont inférieures à celles que nous avons obtenu lorsque nous avons utilisé uniquement des données non bruitées pour l'entraînement. Nous suspectons que l'introduction de bruits dans les images d'entraînement a conduit à une mauvaise reconnaissance des images non bruitées (en plus des images bruitées).

On conclue que le système n'est pas robuste aux bruits poivre et sel.

3.3 Robustesse à l'inversion de contraste

Quand nous entraînons le système sur des images dont le contraste n'a pas été inversé et nous ne testons que sur des images dont le contraste a été inversé, le taux de reconnaissances correctes est de 0% ! Vraiment pas robuste donc.

Quand nous inversons le contraste de 30% des images d'entraînement et de test, le taux de reconnaissances correctes obtenu est de 35%.

Conclusion : le système n'est pas robuste à l'inversion de contraste (contrairement à l'être humain qui en général peut reconnaître sans problème une personne dont le contraste de l'image du visage a été inversé).

3.4 Robustesse à la rotation

Nous entraînons le système sur des images droites (pas de rotation), puis nous testons sur des images retournées aléatoirement (d'un angle multiple de 30°). Nous avons obtenu un taux de reconnaissances correctes de 2%. Donc à la base le système n'est pas robuste à la rotation.

Nous faisons une rotation aléatoire de toutes les images (entraînement et test) d'un angle multiple de 30° (un nouvel angle de rotation est généré aléatoirement pour chaque image). Le taux de reconnaissances correctes obtenu est de 60%, ce qui est relativement proche du score obtenu sans rotation (68%) et est une grande amélioration par rapport à quand on n'avait pas d'images retournées dans les images d'entraînement.

Conclusion : le système à la base n'est pas robuste à la rotation. Pour le rendre plus robuste, il faut introduire des images retournées dans les données d'entraînement.

3.5 Robustesse à la translation

Nous entraînons le système sur des images non traduites, puis nous testons sur des images traduites. Nous avons obtenu un taux de reconnaissances correctes de 7%. Donc à la base le système n'est pas robuste à la translation.

Nous traduisons 30% des images d'entraînement et de test. Le taux de reconnaissances correctes obtenu est de 43%, ce qui est loin du score obtenu sans translation (68%) mais est une grande amélioration par rapport à quand on n'avait pas d'images traduites dans les images d'entraînement (il y a aussi des images de test non traduites ce qui fait monter le taux).

Conclusion : le système à la base n'est pas robuste à la translation. Pour le rendre plus robuste, il faut introduire des images traduites dans les données d'entraînement.

Conclusion

Références

- E. B. Putranto, P. A. Situmorang, and A. S. Girsang. Face recognition using eigenface with naive bayes. In *2016 11th International Conference on Knowledge, Information and Creativity Support Systems (KICSS)*, pages 1–4, Nov 2016.